# Una teoría matemática de la comunicación

Autor original: Claude E. Shannon
Autor del resumen: Acoyani Garrido Sandoval

Artículo original: Octubre de 1948
Resumen: 19 de Marzo de 2026

## 1. Introducción

Desde el año de 1948, ya se habían desarrollado métodos hoy en día básicos de modulación de señales tales como *pulse code modulation* (PCM), hoy en día usado no tanto para transmitir señales físicas sino más bien para representar señales digitales en términos de su valor máximo discretizado casi siempre a 8, 16 o 32 bits; así como el método PPM, el cual ha caído en desuso por la complejidad que representa usarlo para transmitir señales digitales y su escasa practicidad para otros fines. La base de dicha teoría fue desarrollada por otros influyentes pioneros de la ciencia de telecomunicaciones tales como Harry Nyquist, del cual Shannon cita su artículo *"Algunos factores que afectan la velocidad de los telégrafos"*, en el cual Nyquist estudia la distorsión de las señales de los telégrafos de entonces al pasar por el medio de transmisión y propone la técnica de *signal shaping* (darle a cada pulso una forma de onda que minimice la interferencia inducida en otros circuitos), y una elección de códigos de transmisión de señal que maximice la cantidad de *"inteligencia"* que se puede transmitir con un cierto número de elementos de señal.

Podemos ver aquí cómo, desde antes de que Shannon acuñara el concepto, ya se estaba empezando a hablar de una "inteligencia" de las comunicaciones, refiriéndose al contenido que éstos llevan. En su artículo, Shannon nos recuerda que **el problema fundamental de las comunicaciones,** entendidas en su más amplia definición humana, **es reproducir en un punto un mensaje elegido en otro punto de forma exacta o aproximada.** Los mensajes con frecuencia tienen un significado, es decir, hacen referencia o están correlacionadas a algún sistema conforme a entidades físicas o conceptuales: el documento PDF que contiene esta tarea es ultimadamente una señal, representada por la polaridad de los campos magnéticos del plato de alguno de los millones de discos magnéticos que maneja el servicio aws Amazon S3 en el cual está montada la plataforma Canvas, y sin embargo, esta señal tiene un significado específico: su contenido está estructurado especialmente para que, al abrirlo con una aplicación diseñada para decodificar datos conforme al estándar ISO 19005 PDF/A,

en nuestro equipo aparezca una representación digital de un documento impreso que contiene un resumen del artículo de Claude Shannon. Este mensaje, en términos estadísticos, es uno de cualquier mensaje que se pueda enviar con esa misma cantidad de bits; y los sistemas de transmisión y almacenamiento de datos deben estar diseñados de tal forma que funcionen con cualquier conjunto de mensajes posibles.

En este sentido, si el número de mensajes que podemos enviar en un conjunto de símbolos es finito, entonces ese número puede medirse como una medida de la información producida cuando se elige un mensaje de entre el conjunto total, siendo todas las posibles opciones igualmente probables (distribución discreta uniforme). Shannon elige las medidas logarítmicas para medir ese contenido de información en parte porque varias métricas ingenierilmente relevantes, tales como el tiempo de transmisión o el ancho de banda de transmisión necesario, tienden a ser linealmente proporcionales al logaritmo de la cantidad de posibilidades; porque es intuitivo, ya que es fácil dar por sentado que 2 tarjetas perforadas o 2 cubetas de Amazon S3 con límite de tamaño deberían tener el doble de capacidad de almacenamiento que una sola de ellas, o que 2 cables de transmisión deberían tener el doble de capacidad que uno solo; y porque esto simplifica el manejo matemático de varias operaciones.

En este sentido, la base del logaritmo corresponde a cuántas piezas de información se puede representar con nuestra unidad de transmisión o almacenamiento de información. Por ser una unidad fácil de representar a través de un circuito electrónico con 2 estados estables tales como un relevador o un *flip-flop*, es en este artículo que Shannon sugiere usar el dígito binario, o *bit*, como la mínima unidad posible de transmisión o almacenamiento de datos; convención que todavía hoy, 78 años después de la publicación de su artículo, se sigue observando por lo sencillo que ha resultado ser implementarla en físico. Un solo dígito binario, o en términos físicos un solo flip-flop biestable, puede almacenar 2 estados que pueden interpretarse como çierto.º "falso", o como los dígitos 0 y 1. Si añadimos un segundo flip-flop biestable, tenemos ahora 2 bits con los cuales podemos representar $2^2 = 4$ dígitos posibles, y por ende, para poder almacenar 4 dígitos posibles necesitamos $\log_2 4 = 2$ bits. Y si queremos representar 256 dígitos posibles, necesitaremos para ello $\log_2 256 = 8$ bits, correspondientes a 8 flip-flops biestables, 8 agujeros en una tarjeta perforada, 8 pistas de circuito impreso, &c.

Por supuesto, nada nos impide usar dígitos decimales. En este caso, si tuviéramos que usar bits para representarlos, necesitaríamos $\ln 10/\ln 2 \approx 3.32$ bits para representarlos. Y si nos vamos a las matemáticas abstractas, podemos incluso manejar dígitos abstractos capaces de tener $e$ valores, lo que permite usar el logaritmo natural para hacer nuestros cálculos, con la simplificación algebraica que éste trae como resultado.

## 2. El sistema básico de comunicación

Shannon propone un modelo simplificado de sistema de comunicación que consta de una serie de cajas negras encadenadas:

1. **Origen de información:** Cualquier proceso que produzca algún mensaje o señal que es necesario hacer llegar al equipo receptor. Puede ser una secuencia de letras como en un telégrafo o un *chat* instantáneo moderno, una señal analógica $f(T)$ que represente audio, una señal multidimensional $f(x, y, T)$ como es el caso de la televisión o un video, donde $f$ es la intensidad de la luz en un punto, $x, y$ son la posición del punto en la pantalla, y $T$ representa el tiempo discretizado en fotogramas; o incluso múltiples señales simultáneas como en el caso del video a color, que consta de 3 señales de 3 variables que representan los 3 canales de color que generalmente se necesitan para representar el espectro de colores que podemos ver.

2. **Transmisor:** Recibe el mensaje del origen de información, y con base en éste, hace alguna operación que produce una señal que pueda ser transmitida a través del canal. En el teléfono de cobre tradicional, la operación consiste simplemente en convertir las ondas de sonido en ondas eléctricas a través de un micrófono; en medios más modernos la operación es mucho más compleja, pero igualmente debe resultar en la generación de una señal capaz de ser transmitida por nuestro canal.

3. **Canal:** Es el medio a través del cual se transmite la señal del transmisor al receptor. En el caso del teléfono clásico, es un par de cables de cobre; en la radio AM/FM, es una banda de radiofrecuencia; en las líneas terrestres de internet modernas, generalmente es una fibra óptica a través de la cual pasa un rayo de luz. El canal tiene el efecto de **añadir ruido** a la señal transmitida, el cual proviene de una **fuente de ruido**, que representa los fenómenos físicos que resultan en la adición de elementos no deseados a nuestra señal o su distorsión.

4. **Receptor:** Recibe la señal enviada por el transmisor y realiza la operación inversa, reconstruyendo el mensaje a partir de la señal.

5. **Destino:** Es la persona o cosa que recibe el mensaje. Puede considerarse, por ejemplo, que un navegador web es el destino de una secuencia de datos si éstos están codificados en formato JSON, un formato comúnmente usado para transmitir datos para ser leídos y procesados por navegadores web.

## 3. El canal discreto sin ruido

Un canal discreto sin ruido es aquél a través del cual sea posible transmitir una serie de símbolos elementales $S_1, S_2, ..., S_n$ de un punto a otro; cada símbolo $S_i$ tiene una duración de $t_i$. El surtido de símbolos depende del canal; en un telégrafo simple, por ejemplo, los símbolos que pueden pasar son 4: el "punto", la "raya", el espacio entre letras, y el espacio entre palabras; en los teletipos de

aquella época, todos los símbolos tenían la misma duración y había 32 símbolos posibles.

En el caso del teletipo, es sencillo: cada símbolo representa $\log_2 32 = 5$ bits de información; y si el sistema es capaz de transmitir $n$ símbolos por segundo, entonces la capacidad del canal es $5n$ bits/s.

Eventualmente, se caracteriza la capacidad $C$ de un canal discreto como

$$C = \lim_{T \to \infty} \frac{\log N(T)}{T}$$

donde $N(T)$ es la cantidad de símbolos permitidos de duración $T$.

### 3.1. El teorema fundamental

Dados una fuente con $H$ bits por símbolo de entropía y un canal con $C$ bits/s de capacidad, es posible codificar la salida de la fuente de tal forma que ésta transmita a una tasa lo más cerca posible de $C/H$ símbolos por segundo. Es matemáticamente imposible transmitir por encima de este límite.

Shannon establece en el mismo artículo la *codificación Shannon-Fano*, haciendo referencia a un método de codificación de fuente previamente propuesto por R. M. Fano. Desde entonces se han desarrollado algoritmos de codificación de fuente más eficaces, hoy mejor conocidos como *algoritmos de compresión*, tales como la transformada de Burrows-Wheeler (bzip2), el algoritmo de Huffman, el algoritmo DEFLATE (ZIP/gzip), el archivador de Eugene y Alexander Roshal (RAR), o el algoritmo Lempel-Ziv-cadena de Markov (LZMA).

## 4. Caracterización de la fuente de información

La fuente de información puede caracterizarse a través de un **proceso de Markov**, el cual inicialmente se modela como un grafo donde cada nodo es uno de los posibles símbolos que la fuente puede emitir, y cada arista es la probabilidad de que un símbolo siga después de otro. Una *fuente ergódica* es aquella cuya cadena de Markov no consta de 2 partes aisladaas a través de las cuales es imposible transitar en términos de la información generada, y donde el máximo común divisor de las longitudes de los circuitos de la cadena de Markov sea 1 (de lo contrario la fuente de información produciría patrones periódicos).

A través del análisis matemático de las probabilidades de transición en el modelo de Markov, llegamos eventualmente a una métrica $H$ capaz de representar cuánto "surtido de elección" hubo en la generación del mensaje producido por la fuente:

$$H = -\sum_{n=1}^{n} p_i \log p_i$$

donde $K$ es una constante positiva, y $p_i$ es la probabilidad de que ocurra alguno de los posibles símbolos de nuestra fuente.

Esta función $H$ es la **entropía de la información,** que representa la cantidad de bits que es necesaria para representar la salida de nuestra fuente. Este concepto forma parte de numerosas aplicaciones tales como los *algoritmos de compresión de entropía*, que funcionan a través de recodificar una secuencia de datos (e.g. un archivo) de tal forma que su entropía se acerque lo más posible a 8 bits por byte. Esta función cumple **3 axiomas**: $H$ es continua en $p_i$, $H$ crece monotónicamente en $n$ para eventos de probabilidad uniforme $p_i = \frac{1}{n}$, y $H$ es aditiva para **elecciones compuestas** (descomponer una elección de símbolo en elecciones sucesivas da como resultado sumas ponderadas, esto es el fundamento de la ganancia de información).

En cuanto a los órdenes de las fuentes de información, éstos son:

- **Orden 0**: Símbolos elegidos independientemente con igual probabilidad.
- **Orden 1**: Símbolos elegidos independientemente con la probabilidad del "idioma" de nuestra fuente.
- **Orden 2**: Dígrafos (conjuntos de 2 letras) incorporados mediante una cadena de Markov.
- **Órdenes superiores**: Idem, pero con conjuntos de n letras.

Para una fuente que se puede describir como una cadena de Markov, la entropía es:

$$H = \sum_i P_i H_i = -\sum_{i,j} P_i p_i(j) \log p_i(j)$$

donde $P_i$ son las probabilidades de los estados de la cadena de Markov, y $p_i(j)$ son las probabilidades de las transiciones de la cadena.

# 5. Redundancia

La **entropía relativa** $H_{rel}$ de una fuente de información es la división de su entropía observada entre la máxima entropía posible. La **redundancia** es $1 - H_{rel}$.

La redundancia hoy en día se puede interpretar como la *compresibilidad* de un archivo o fuente de información, en el entendido de que los algoritmos de compresión, en principio, funcionan a través de recodificar la información de tal forma que su entropía observada se acerque lo más posible a la entropía máxima teórica. Esto también trae como resultado que *no se puede comprimir más lo que ya está comprimido*, pues en teoría el algoritmo de compresión ya maximizó la entropía de la información.

# 6. El canal ruidoso

Los canales de transmisión en la vida real son ruidosos, por lo que éstos se modelan como una función de la señal transmitida $S$ y el ruido $N$ que es $E = f(S, N)$. Se caracteriza a detalle en términos de transiciones de probabilidad $p_{\alpha,i}(\beta, j)$: la probabilidad de que, en el estado $\alpha$ y la transmisión de un símbolo $i$, que se reciba $j$ y el canal pase al estado $\beta$.

La **equivocación** $H_y(x)$ es la entropía condicional de la señal transmitida dada la señal recibida, es decir, la ambigüedad promedio acerca de lo que se transmitió:

$$R = H(x) - H_y(x)$$
$$R = H(x) + H(y) - H(x, y)$$

En teoría, debería ser posible establecer un **canal de corrección** (un hipotético dispositivo o algoritmo que sea capaz de tomar nota de los errores de transmisión) de tal forma que, si su capacidad es $H_y(x)$, entonces sea posible corregir los errores hasta una fracción infinitesimal, pero nunca todos. Esto es imposible si la capacidad del canal de corrección es menor que $H_y(x)$.

## 6.1. Teorema fundamental del canal ruidoso

Dado un canal discreto con capacidad $C$ y una fuente discreta con entropía $H$. Si $H \leq C$, en teoría existe un sistema de codificación que permite que la salida de la fuente pueda ser transmitida con una equivocación arbitrariamente baja. Pero si $H > C$, entonces más bien la fuente debería ser codificada de tal forma que la equivocación sea menor que $H - C + \epsilon$ para una $\epsilon$ arbitrariamente baja, y es imposible lograr una equivocación menor que $H - C$.